Tecnológico de Monterrey

Benchmarking de voz multimodal: evaluación de equidad lingüística

Alejandro Agustín Ahedo González Andrés Roberto Osuna González
Sandra Luz Cervantes Espinoza

Proyecto Integrador · Maestría en Inteligencia Artificial Aplicada

Asesoría académica: Dra. Liliana Ibeth Barbosa Santillán,
Dra. Grettel Barceló Alonso y Dr. Luis Eduardo Falcón Morales

Resumen

La expansión de los sistemas de reconocimiento automático del habla (Automatic Speech Recognition, ASR) hace necesario evaluar su desempeño más allá de los idiomas con alta disponibilidad de recursos digitales. Este artículo presenta un estudio comparativo multilingüe cuyo propósito es caracterizar las diferencias de precisión, eficiencia y equidad entre arquitecturas ASR, así como establecer las condiciones necesarias para valorar su transferencia a un entorno operativo. Se empleó el corpus FLEURS y se implementó un flujo reproducible de preprocesamiento y normalización acústica y textual. El análisis exploratorio permitió identificar que una aplicación uniforme de Word Error Rate (WER) produce mediciones engañosas en idiomas cuya escritura no separa palabras mediante espacios; por ello se incorporó Character Error Rate (CER) como métrica comparable a nivel de carácter. En la etapa de comparación de modelos individuales, Whisper-Large-v3 obtuvo el menor WER promedio reportado (4.39 %), seguido por Qwen3-ASR (7.15 %) y SeamlessM4T (7.20 %), mientras que Omnilingual ASR CTC 300M alcanzó 19.28 %. En la etapa de optimización y selección se realizó una evaluación focalizada de Whisper, con particiones independientes de validación y prueba. Los resultados de esa ejecución muestran un CER de 4.91 %, WER de 8.03 % para idiomas con separación por espacios y 1.491 segundos por audio para la configuración greedy. Se proponen decisiones de aceptación, un plan de retroceso metodológico y una arquitectura MLOps para una operación confiable, escalable y auditable.

Palabras clave: reconocimiento automático del habla, ASR, FLEURS, equidad lingüística, WER, CER, Whisper-Large-v3, lenguas de bajos recursos, MLOps.

1. Contexto de negocio y problema

1.1. Organización y motivación

El estudio se desarrolló en colaboración con CLEAR (Coalition for Language Equity in AI Research), iniciativa interdisciplinaria orientada a promover que el desarrollo de inteligencia artificial beneficie también a comunidades hablantes de idiomas subrepresentados. El repositorio técnico del equipo se encuentra en https://github.com/Luz026/VoiceBenchmark.

La motivación central es que el desempeño agregado de los sistemas de voz puede ocultar diferencias importantes entre idiomas, sistemas de escritura y comunidades de hablantes. Un sistema que obtiene resultados favorables en inglés o español no necesariamente conserva la misma calidad en lenguas con menor presencia en los datos de entrenamiento, alfabetos distintos o convenciones ortográficas diferentes. Esta asimetría puede limitar el acceso equitativo a servicios educativos, gubernamentales, de salud e interfaces digitales que dependen de la comunicación oral.

1.2. Problema y objetivo técnico

El problema consiste en la ausencia de un procedimiento comparativo homogéneo que permita evaluar arquitecturas ASR y modelos multimodales en condiciones multilingües, distinguiendo precisión global de desempeño por idioma. El objetivo general fue comparar cuantitativamente modelos de reconocimiento automático del habla mediante WER y CER, con énfasis en lenguas de bajos recursos y diferencias asociadas con la arquitectura y el sistema de escritura.

La pregunta que orienta la decisión de implementación es: ¿la evidencia experimental disponible es suficiente para operar la solución y, si no lo es, qué decisiones deben tomarse antes de avanzar a producción? Para responderla se consideran no solo las métricas de error, sino también la representatividad de los datos, la reproducibilidad, la latencia, la capacidad operativa y los mecanismos de supervisión.

1.3. Evolución del proyecto y decisiones relevantes

El proyecto evolucionó desde una evaluación amplia de cobertura lingüística hacia una comparación de modelos y, finalmente, hacia una evaluación focalizada de estrategias de inferencia. Esta evolución puede sintetizarse en cinco hitos técnicos, sin atribuir a cada hito actividades que no estén respaldadas por los entregables disponibles:

1. **Caracterización del problema y del corpus.** Se definió la equidad lingüística como una dimensión que no puede inferirse únicamente del promedio global y se seleccionó FLEURS como fuente de evaluación multilingüe.
2. **Preparación y diagnóstico de métricas.** El análisis exploratorio evidenció que WER basado en separación por espacios penalizaba artificialmente idiomas como japonés. Se incorporó CER como métrica transversal.
3. **Establecimiento de línea base.** Omnilingual ASR CTC 300M permitió obtener una referencia de cobertura amplia y caracterizar la variabilidad del error entre idiomas.
4. **Comparación de alternativas.** Se evaluaron Omnilingual ASR, Qwen3-ASR, SeamlessM4T y Whisper-Large-v3. Whisper obtuvo el menor WER promedio reportado en ese protocolo, por lo que se priorizó para la siguiente evaluación.
5. **Optimización y decisión de implementación.** Se compararon estrategias de decodificación de Whisper en particiones de validación y prueba. El procedimiento final seleccionó greedy por el criterio programado de CER y desempate por tiempo, aunque la evaluación contiene dos excepciones de audios largos que deben corregirse.

Esta secuencia documenta las decisiones que modificaron el alcance: primero se corrigió la métrica, después se utilizó una línea base de amplia cobertura, luego se compararon arquitecturas y

finalmente se optimizó la inferencia del candidato priorizado. Los entregables proporcionados no incluyen una bitácora fechada completa de cada Avance 1–5; por ello, los cinco hitos anteriores describen la evolución técnica comprobable y no sustituyen una cronología administrativa de entregas.

2. Datos y preparación

2.1. Corpus, cobertura y particionamiento

El conjunto principal fue FLEURS (*Few-shot Learning Evaluation of Universal Representations of Speech*), corpus público multilingüe utilizado para tareas de reconocimiento y representación del habla. La documentación de los conjuntos de datos debe incluir procedencia, composición, usos previstos y limitaciones, en línea con las prácticas de documentación sistemática de datos.

Los entregables reportan cifras de corpus distintas entre etapas. En el análisis exploratorio se registraron 5,150 audios y 103 idiomas; en la línea base se procesaron 5,087 transcripciones correspondientes a 102 idiomas. En la etapa de optimización se construyó una muestra focalizada de ocho idiomas, con 50 audios por idioma (400 en total). Se reservaron 10 audios por idioma para validación y otros 10 diferentes para prueba; los 30 restantes por idioma no se utilizaron en esas dos particiones.

Tabla 1: Volumen de datos reportado por etapa metodológica.

Etapa	**Volumen**	**Uso y observación**
Análisis exploratorio	5,150 audios; 103 idiomas	50 audios por idioma; semilla 42, según el entregable.
Línea base	5,087 registros; 102 idiomas	Registros efectivamente evaluados con Omnilingual ASR.
Optimización y selección	400 audios; 8 idiomas	80 para validación, 80 para prueba y 240 no utilizados en esas particiones.

La diferencia entre 5,150/103 y 5,087/102 debe conservarse como una diferencia entre etapas y no interpretarse como una inconsistencia resuelta. Antes de una nueva publicación de resultados se recomienda documentar los identificadores excluidos, la razón de exclusión y la versión exacta de cada partición.

2.2. Control de calidad y normalización

El análisis exploratorio confirmó que los registros estructurales principales estaban disponibles y que los audios podían decodificarse. También identificó dos riesgos: diferencias ortográficas entre referencia y predicción, y uso inadecuado de WER en lenguas sin separación convencional por espacios.

El flujo de preparación incluyó remuestreo a 16 kHz, conversión a canal mono, representación numérica `float32`, padding dinámico y batching. La normalización textual utilizó Unicode NFKC, conversión a minúsculas y limpieza controlada de puntuación y espacios. Se incorporó mapeo de códigos de idioma cuando las convenciones del modelo diferían de los identificadores del corpus,

almacenamiento en caché persistente y semilla fija. La caché redujo el tiempo de preparación reportado de aproximadamente 106 minutos a menos de un minuto en ejecuciones posteriores.

La normalización debe ser específica por idioma. No debe eliminar diacríticos ni signos que distingan significado, pronunciación o categorías gramaticales. Toda transformación debe versionarse y aplicarse de manera idéntica a las referencias y a las hipótesis.

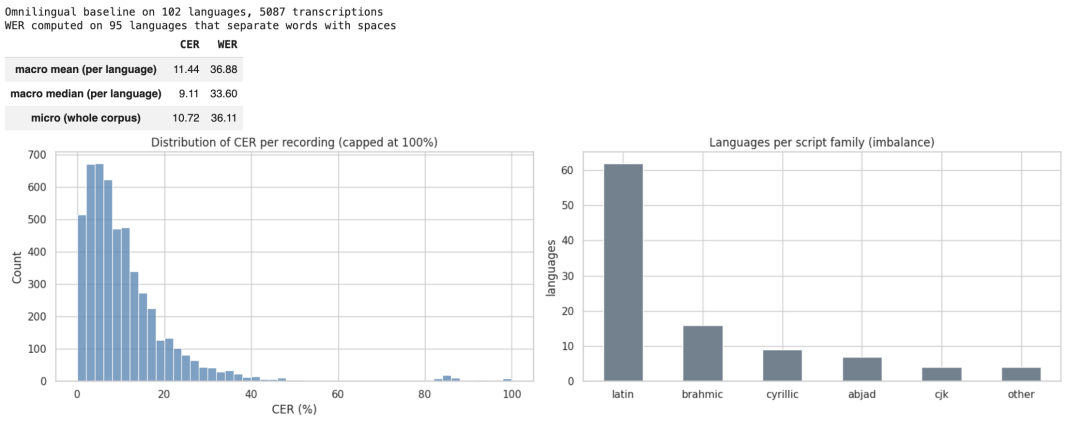


Figura 1: Distribución de muestras por idioma y cobertura del corpus FLEURS.

2.3. Métricas y adecuación lingüística

La tasa de error de palabras se define como:

$$WER = \frac{S + D + I}{N},$$

donde S, D e I representan sustituciones, eliminaciones e inserciones de palabras, y N es el número de palabras de referencia. La tasa de error de caracteres se calcula de forma análoga a nivel de carácter:

$$CER = \frac{S_c + D_c + I_c}{N_c}.$$

Ambas métricas pueden superar 100 % cuando existen numerosas inserciones.

WER presupone una segmentación de palabras consistente. En idiomas cuya escritura no separa convencionalmente las palabras mediante espacios, una tokenización ingenua puede producir valores poco interpretables. La literatura reciente recomienda considerar CER para la evaluación multilingüe en esos escenarios. En el análisis inicial del equipo, el WER de Whisper-Large-v3 para japonés alcanzó 74.99

Por tanto, este artículo utiliza CER como métrica transversal y WER como indicador complementario únicamente en idiomas donde la segmentación por espacios resulta adecuada. Para futuras comparaciones deberán fijarse además reglas de normalización, tratamiento de puntuación, Unicode y segmentación antes de ejecutar los modelos.

3. Metodología y modelos

3.1. Diseño experimental

El proceso siguió una secuencia inspirada en CRISP-ML(Q), que integra aseguramiento de calidad durante el ciclo de vida de los sistemas de aprendizaje automático: entendimiento del negocio, entendimiento y preparación de datos, modelación, evaluación y consideración del despliegue. Se estableció una línea base, se compararon alternativas y se optimizó la inferencia de Whisper-Large-v3.

En la etapa de optimización, los parámetros se seleccionaron utilizando un conjunto de validación independiente y el conjunto de prueba se reservó para estimar el rendimiento final. Esta separación es necesaria para reducir el riesgo de ajustar decisiones al conjunto de prueba. No obstante, las excepciones técnicas detectadas en dos audios de prueba impiden tratar los resultados de esa ejecución como una estimación final cerrada.

3.2. Línea base: Omnilingual ASR CTC 300M

Omnilingual ASR CTC 300M se utilizó como referencia por su cobertura lingüística amplia y arquitectura CTC. El entregable reporta CER macro de 11.4

También se reportó un coeficiente de Gini de 0.299 y una razón máximo/mínimo de CER de 19.6. El Gini debe interpretarse aquí como una medida de desigualdad en la distribución de los valores de error entre idiomas: un valor mayor representa una distribución más desigual y un valor menor, una distribución más homogénea. No mide dispersión de señales de audio ni constituye por sí mismo una medida completa de equidad. Su interpretación depende de la población de idiomas incluida, del tratamiento de valores cero y de si se calcula sobre CER por idioma con ponderación uniforme.

La línea base también exploró la predicción del CER a partir de características del idioma, audio, texto y hablantes. La varianza del CER se descompuso en 42.5

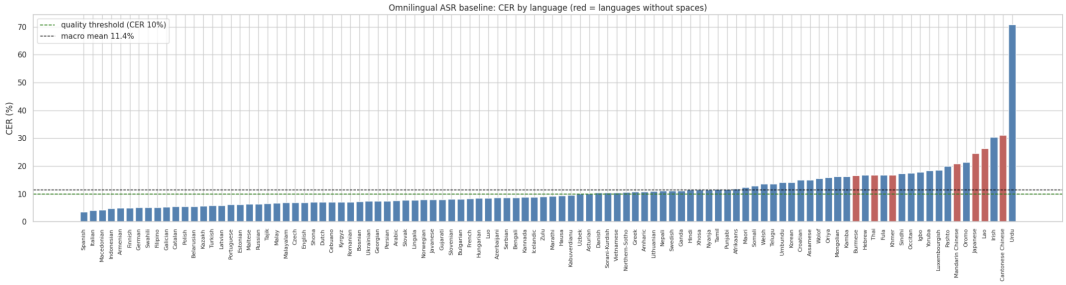


Figura 2: CER de Omnilingual ASR CTC 300M por idioma durante la etapa de línea base.

3.3. Comparación de modelos individuales

En la etapa comparativa se evaluaron Omnilingual ASR CTC 300M, Qwen3-ASR-0.6B, SeamlessM4T y Whisper-Large-v3. Los informes técnicos de los modelos describen capacidades y objetivos distintos; por ello, sus resultados publicados no sustituyen la comparación experimental realizada por el equipo.

Tabla 2: Resultados agregados reportados en la etapa comparativa.

Modelo	WER promedio reportado
Whisper-Large-v3	4.39 %
Qwen3-ASR-0.6B	7.15 %
SeamlessM4T	7.20 %
Omnilingual ASR CTC 300M	19.28 %

En ese protocolo, Whisper-Large-v3 obtuvo el menor WER promedio reportado. Sin embargo, los modelos no deben declararse universalmente ordenados sin verificar que las cifras proceden exactamente de las mismas muestras, normalización, idioma, hardware y configuración. El modelo con mayor cobertura lingüística tampoco necesariamente obtiene el menor error en el subconjunto evaluado.

La evaluación por familia de escritura reportó un CER medio de 22.7

3.4. Optimización y selección de Whisper-Large-v3

En la etapa de optimización se utilizó exclusivamente `openai/whisper-large-v3`. No se reentrenaron sus pesos ni se modificó la arquitectura; se compararon estrategias de decodificación: greedy (`num_beams=1`), Beam Search (`num_beams=3` y `num_beams=5`) y consenso homogéneo por medoide de tres hipótesis.

La muestra incluyó 400 audios de ocho idiomas: inglés, español latinoamericano, francés, alemán, italiano, ruso, japonés y chino mandarín. Se reservaron 10 audios por idioma para validación y otros 10 para prueba, lo que produjo 80 audios en cada partición. Los 30 restantes por idioma no se utilizaron en esos conjuntos.

La validación favoreció Beam Search con `num_beams=5` y `length_penalty=1.0`. Sin embargo, el procedimiento final de selección aplicado sobre el conjunto de prueba eligió greedy de acuerdo con el criterio programado de CER y desempate por tiempo. Es importante distinguir ambos resultados: Beam Search fue la mejor configuración observada en validación, mientras que greedy fue la estrategia seleccionada por el procedimiento final.

Tabla 3: Resultados reportados por el bloque de selección final de la etapa de optimización.

Indicador	**Resultado reportado**
Arquitectura	Whisper-Large-v3
Estrategia seleccionada por el procedimiento final	Greedy
Mejor configuración observada en validación	Beam Search, `num_beams=5`
CER en prueba (greedy)	4.91 %
WER en idiomas con espacios (greedy)	8.03 %
Coincidencia exacta (greedy)	33.75 %
Tiempo promedio (greedy)	1.491 s/audio
Tamaño nominal de prueba	80 audios; 8 idiomas

La coincidencia exacta es más estricta que CER o WER: una transcripción puede contener pocos errores de carácter y aun así no coincidir exactamente con la referencia. El 33.75 % no debe interpretarse como exactitud de clasificación ni como equivalente a $1 - CER$.

	Método	Tiempo promedio (s/audio)
0	Whisper base (greedy)	1.491
1	Whisper optimizado	2.625
2	Ensamble homogéneo (3 hipótesis)	6.258

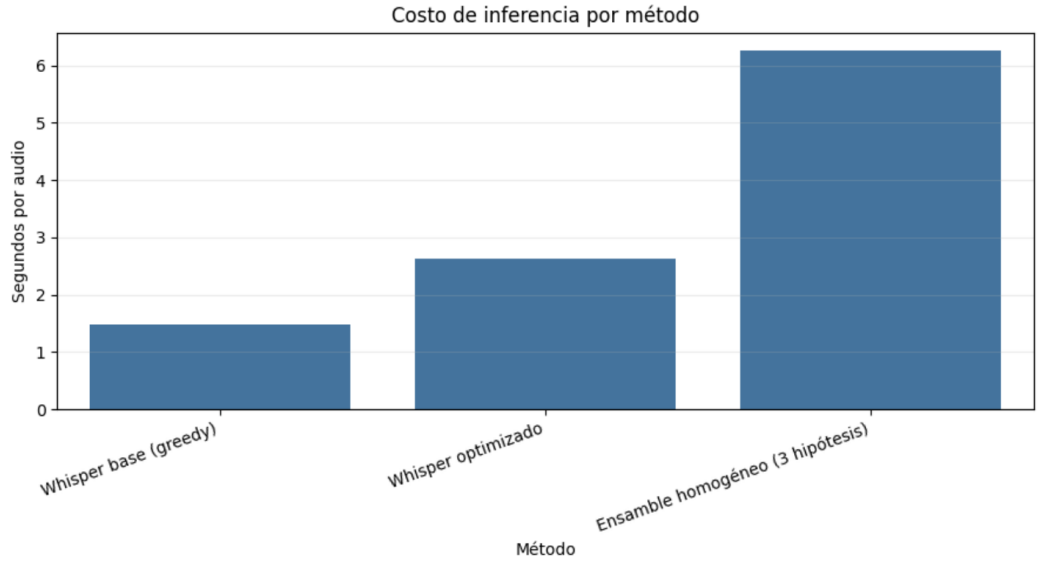


Figura 3: Comparación en prueba no vista entre greedy, Beam Search optimizado y consenso medoide, todos basados en Whisper-Large-v3.

4. Resultados y validación

4.1. Síntesis de hallazgos y comparación con la línea base

Los resultados permiten identificar dos hallazgos principales. Primero, la elección de la métrica modifica sustancialmente la interpretación del desempeño: WER no es adecuado como métrica transversal para todas las escrituras y CER permite una comparación a nivel de carácter más consistente. Segundo, los promedios globales ocultan diferencias entre idiomas y familias de escritura, por lo que la aceptación debe basarse en métricas desagregadas.

La línea base de Omnilingual reportó CER macro de 11.4

Tabla 4: Lectura cuantitativa de los resultados y límites de comparabilidad.

Indicador	**Valor**	**Interpretación**
CER macro de línea base (Omnilingual)	11.4 %	Resultado de la etapa de línea base, 102 idiomas.
CER de prueba focalizada (Whisper greedy)	4.91 %	Resultado reportado para ocho idiomas y 80 audios nominales.
Diferencia aritmética	6.49 pp	Resta descriptiva entre cifras de protocolos distintos.
Reducción relativa aparente	56.9 %	Cálculo descriptivo; no es lift atribuible al cambio de modelo.
WER promedio comparativo de Whisper	4.39 %	Pertenece a la etapa comparativa y no debe confundirse con el WER 8.03 % de la prueba focalizada.

Por tanto, el resultado principal que puede sostenerse es que Whisper fue el candidato con mejor WER promedio en la comparación reportada y que su configuración greedy obtuvo CER de 4.91 % en la evaluación focalizada. No puede afirmarse todavía que haya mejorado 56.9

4.2. Validez de la prueba y limitaciones experimentales

La ejecución final presenta una limitación que afecta la interpretación de sus métricas: dos audios de prueba de más de 30 segundos, uno en alemán y otro en italiano, generaron excepciones durante el manejo de generación larga. El código sustituyó esas salidas por cadenas vacías. Si dichas salidas se incluyeron en el cálculo, CER, WER y coincidencia exacta pueden estar sesgados. En consecuencia, los valores reportados deben etiquetarse como provisionales hasta corregir el procesamiento y recalcular las métricas.

La ejecución se realizó en Google Colab con GPU Tesla T4 y aproximadamente 14.56 GB de VRAM, aunque la configuración experimental recomendaba al menos 16 GB. También deben considerarse las siguientes limitaciones:

1. FLEURS contiene grabaciones de lectura relativamente limpias; no representa por sí solo conversación espontánea, ruido, solapamiento de voces ni micrófonos heterogéneos.
2. La etapa comparativa y la etapa de optimización utilizaron subconjuntos y protocolos distintos; sus métricas no forman un ranking pareado.

3. La muestra de prueba focalizada comprende 80 audios nominales y ocho idiomas, por lo que no permite generalizar a todos los dialectos ni a todas las condiciones de uso.
4. La evaluación no incluyó pruebas de carga, concurrencia sostenida ni costo por minuto en un entorno productivo.
5. Los resultados de los modelos tabulares para predecir CER fueron débiles en prueba y no justifican su uso como filtro automático.

4.3. Umbrales de aceptación propuestos

Los umbrales siguientes son criterios preliminares de piloto y no resultados observados. Deben ser aprobados por CLEAR y por los responsables del caso de uso, y recalibrarse según el riesgo de la aplicación.

Tabla 5: Umbrales propuestos para decidir la aceptación en un piloto controlado.

Dimensión	**Criterio propuesto**	**Acción si no se cumple**
Calidad global	CER macro $\leq 8\,\%$ en el conjunto objetivo; WER solo donde sea válido.	Revisar normalización, segmentación y configuración; si persiste, regresar a modelación.
Equidad lingüística	Ningún idioma prioritario con CER $> 15\,\%$ sin mitigación documentada.	No habilitar uso autónomo; ampliar datos y evaluar alternativas.
Robustez	Sin excepciones de procesamiento ni transcripciones vacías no justificadas.	Bloquear liberación y corregir el flujo.
Latencia	Percentil 95 dentro del SLA definido por producto.	Optimizar batching, hardware o estrategia de decodificación.
Gobierno	Trazabilidad de datos, modelo, parámetros, métricas y fallback.	No promover a producción hasta completar controles.

Un CER global aceptable no garantiza equidad. Se requiere publicar CER por idioma, tamaño de muestra e intervalos de confianza. Cuando la muestra por idioma sea pequeña, la decisión debe considerar incertidumbre y revisión de hablantes competentes. Los umbrales propuestos deben distinguir aplicaciones de bajo riesgo de usos de alto impacto, como dictado médico, trámites o captura financiera.

5. Implementación y operación

5.1. Decisión de implementación

Se recomienda avanzar a un piloto controlado, no a un despliegue general en producción. Whisper-Large-v3 greedy puede mantenerse como configuración de referencia provisional para los idiomas y tareas evaluados, siempre que exista revisión humana, mecanismo de abstención o fallback y trazabilidad de cada transcripción.

La decisión está condicionada a: (a) corregir el procesamiento de los dos audios largos; (b)

recalcular métricas con salidas válidas; (c) repetir el benchmark desde un entorno limpio y versionado; (d) ampliar la evaluación por idioma y dialecto; (e) ejecutar pruebas de latencia, concurrencia y costo; y (f) aprobar umbrales y controles de gobernanza. Si las brechas por idioma persisten, debe retrocederse a preparación de datos o modelación en lugar de ocultarlas mediante un promedio global.

5.2. Matriz de decisiones, acciones y responsables

La siguiente matriz transforma los hallazgos en actividades verificables. Los responsables se expresan por función operativa, ya que los entregables disponibles no asignan nombres individuales a cada responsabilidad.

Tabla 6: Matriz de decisiones y responsabilidades propuestas.

Hallazgo o riesgo	**Decisión**	**Acción verificable**	**Responsable propuesto**
WER no es comparable para todas las escrituras.	CER como métrica transversal y WER complementario.	Versionar normalización por idioma y pruebas unitarias para japonés, chino y otras escrituras.	Ciencia de datos
Diferencias de error entre idiomas.	No aceptar solo con promedio global.	Publicar CER por idioma, familia de escritura, tamaño de muestra e intervalo de confianza.	Evaluación lingüística
Dos audios largos generaron excepciones.	Bloquear la aprobación definitiva de la prueba actual.	Implementar segmentación o manejo de generación larga; repetir inferencia y métricas.	Ingeniería ML
Comparación entre etapas no pareada.	No reportar la diferencia descriptiva como lift causal.	Ejecutar baseline y candidato con los mismos audios, particiones y normalización.	Ciencia de datos
Greedy fue seleccionado por el procedimiento final.	Mantenerlo como referencia provisional.	Comparar calidad, latencia p50/p95 y VRAM en hardware objetivo.	Ingeniería ML
Capacidad productiva no medida.	No declarar SLA ni costo productivo todavía.	Pruebas de carga, concurrencia, throughput y costo por minuto.	MLOps / Plataforma
Datos de audio potencialmente sensibles.	Aplicar privacidad desde el diseño.	Definir cifrado, retención, borrado, acceso y autorización de uso.	Seguridad / Privacidad

5.3. Criterios para retroceder a fases anteriores

El ciclo debe permitir regresar a fases previas cuando la evidencia lo requiera:

- **Entendimiento de datos:** regresar si la muestra no representa idiomas, dialectos o condiciones acústicas objetivo, o si el tamaño por subgrupo no permite estimaciones estables.
- **Preparación de datos:** regresar si aparecen audios corruptos, frecuencias inconsistentes, etiquetas erróneas, transcripciones desalineadas, normalización que elimina diacríticos o métricas inadecuadas para la escritura.
- **Modelación:** regresar si el modelo incumple umbrales después de validar los datos, si existe una brecha persistente entre idiomas o si otra arquitectura mejora calidad sin exceder el presupuesto operativo.
- **Evaluación:** repetir si se detecta fuga de información, reutilización del conjunto de prueba para ajustar parámetros, excepciones no tratadas o falta de reproducibilidad.

5.4. Arquitectura propuesta para producción

Se propone una arquitectura modular que separe recepción de audio, preparación, inferencia, respuesta y observabilidad. La arquitectura es una propuesta de ingeniería derivada de los requisitos identificados; no representa un despliegue que ya haya sido ejecutado.

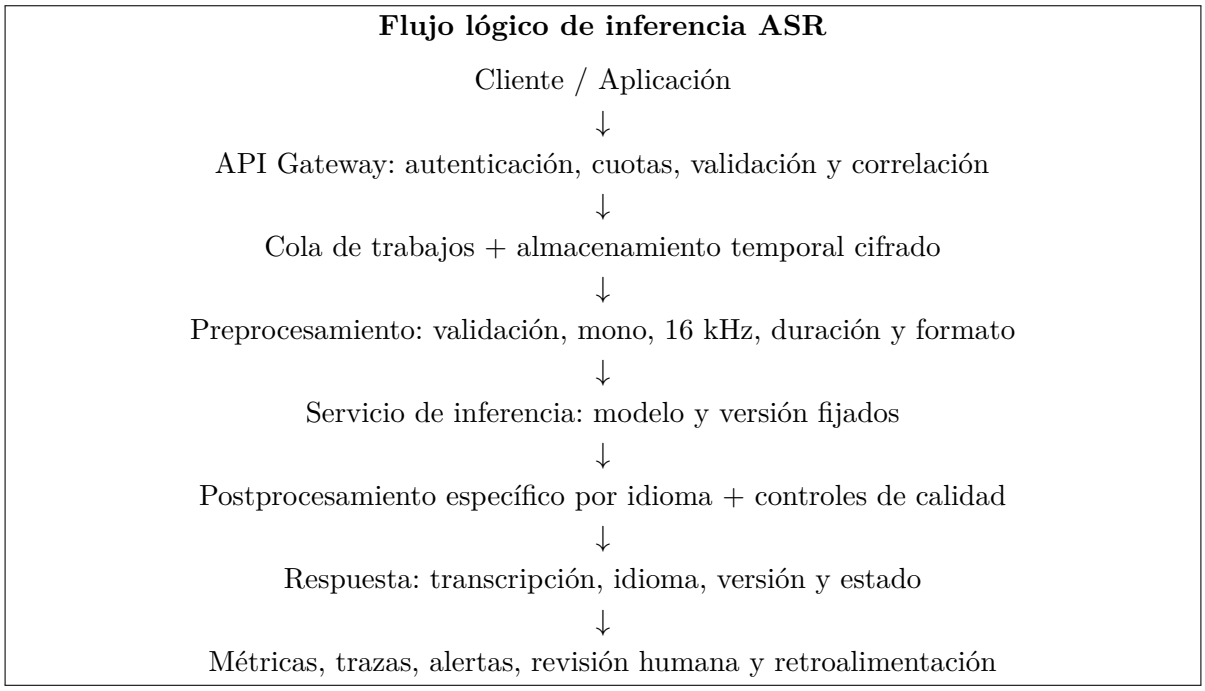


Figura 4: Arquitectura lógica propuesta para operación de un servicio ASR con controles de calidad y observabilidad.

Capa de entrada. El API Gateway valida tipo MIME, tamaño, duración, frecuencia de muestreo y autorización. Cada solicitud debe contar con un identificador de correlación. Los registros generales no deben almacenar audio ni transcripciones sensibles en texto claro.

Capa de procesamiento. Los audios se convierten al formato canónico del benchmark: mono, 16 kHz y tipo numérico compatible. El servicio valida decodificación y duración, registra transformaciones y aplica normalización textual específica por idioma, conservando diacríticos relevantes.

Capa de inferencia. El modelo se empaqueta en un contenedor inmutable con versiones fijadas de Python, PyTorch, Transformers, CUDA y dependencias. Los pesos se identifican por versión o hash. El despliegue puede utilizar GPU con memoria suficiente, réplicas horizontales y cola de trabajos. La capacidad de CPU no debe suponerse equivalente a GPU sin mediciones.

Capa de respuesta. La respuesta incluye transcripción, idioma, versión del modelo, estado de procesamiento y advertencias pertinentes. Una estimación de confianza solo debe exponerse si fue calibrada y validada; no puede inferirse directamente de CER. Para idiomas no habilitados o entradas fuera de distribución, el sistema debe advertir, solicitar revisión o derivar a un motor alternativo.

Datos y privacidad. Los audios pueden contener información personal. Se recomienda cifrado en tránsito y reposo, retención mínima, controles de acceso por rol, eliminación programada y separación entre datos operativos y conjuntos de entrenamiento. La recolección adicional requiere consentimiento o autorización aplicable y documentación del propósito, licencia y retención.

5.5. Confiabilidad, escalabilidad y eficiencia

La confiabilidad requiere pruebas automatizadas de contrato, regresión por idioma, validación de archivos, control de versiones y despliegues graduales. La gestión de riesgos debe cubrir contexto de uso, medición y gobierno del sistema, en línea con el marco NIST AI RMF (NIST, 2023). La ficha del modelo debe documentar uso previsto, evaluación y limitaciones, siguiendo las recomendaciones de Mitchell et al. (2019). Cada versión liberada debe superar un conjunto fijo de audios de referencia y demostrar que no degrada CER/WER más allá de tolerancias acordadas. Se recomienda despliegue *canary* y rollback ante fallas.

La escalabilidad se aborda desacoplando API y trabajadores de inferencia. Una cola absorbe picos y controla la concurrencia según la memoria GPU disponible. El escalamiento automático debe considerar profundidad de cola, utilización de GPU y latencia. Deben medirse throughput, tiempo de espera, duración de inferencia y VRAM.

La eficiencia debe evaluarse comparando el costo de precisión adicional de Beam Search y consenso medoide frente a greedy. El consenso genera varias hipótesis con la misma arquitectura y puede requerir más tiempo y memoria. No se recomienda habilitarlo por defecto hasta confirmar su beneficio en evaluación reproducible y hardware objetivo.

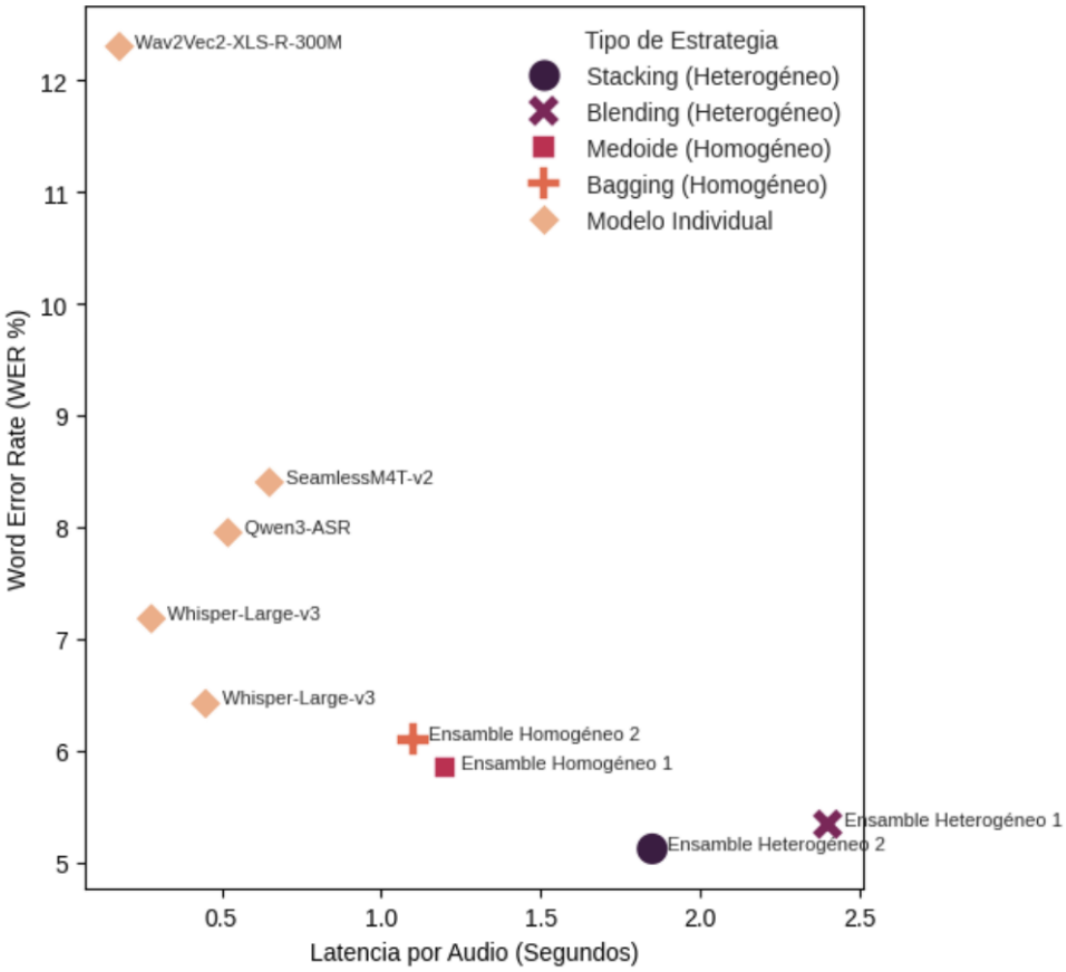


Figura 5: Relación entre calidad y latencia para las configuraciones de decodificación comparadas.

5.6. Monitoreo, indicadores y gobierno

El monitoreo debe cubrir cuatro dimensiones:

1. **Operación:** disponibilidad, tasa de errores, latencia p50/p95/p99, profundidad de cola, throughput, utilización de GPU y VRAM.
2. **Calidad:** CER y WER en muestras etiquetadas, tasa de transcripciones vacías, longitud anómala, idioma y tasa de revisión humana.
3. **Equidad:** métricas por idioma, familia de escritura y dialecto cuando existan metadatos confiables; diferencias entre grupos y tamaño de muestra.
4. **Datos:** cambios en duración, ruido, frecuencia de muestreo y distribución de idiomas respecto del conjunto de referencia.

Como no existen transcripciones de referencia para cada solicitud en producción, la calidad real no siempre puede calcularse en línea. Se propone evaluación diferida sobre muestras autorizadas y etiquetadas, además de auditorías periódicas con hablantes competentes.

Tabla 7: Indicadores operativos y propósito de supervisión.

Indicador	Uso operativo
Latencia p50, p95 y p99	Verificar experiencia de usuario y cumplimiento del SLA.
CER/WER por idioma	Detectar degradación cuando existan transcripciones de referencia.
Tasa de errores, reintentos y salidas vacías	Identificar inestabilidad o fallas de integración.
GPU, VRAM, throughput y concurrencia	Dimensionar recursos y ajustar capacidad.
Distribución de idiomas y duración	Detectar cambios de tráfico y entradas fuera de distribución.
Brecha entre grupos	Evitar que una mejora global oculte deterioro en un idioma.
Costo por minuto procesado	Comparar alternativas y controlar presupuesto.
Tasa de derivación humana	Medir incertidumbre operacional y carga de supervisión.

Los responsables operativos propuestos son: responsable de modelo para versionado y calidad; equipo MLOps para despliegue, capacidad y observabilidad; responsable de datos para particiones y trazabilidad; y responsable de gobernanza/privacidad para autorizaciones, retención e incidentes. La asignación nominal deberá aprobarse en el plan de operación.

6. Conclusiones clave

El estudio desarrolló un flujo reproducible de evaluación ASR y mostró que la definición de métricas forma parte central de la evaluación de equidad lingüística. El hallazgo metodológico principal es que WER no debe aplicarse uniformemente a idiomas sin segmentación por espacios. CER ofrece una comparación a nivel de carácter más adecuada para estos casos, siempre que la normalización preserve las particularidades ortográficas de cada lengua. En la etapa comparativa, Whisper-Large-v3 presentó el menor WER promedio reportado (4.39 %) entre los cuatro modelos evaluados. En la evaluación focalizada posterior, el procedimiento final seleccionó la configuración greedy y reportó CER de 4.91

La decisión de implementación es condicional: se recomienda un piloto supervisado y posponer el despliegue general. Antes de liberar el servicio deben corregirse las excepciones de los dos audios largos, recalcularse las métricas, ampliarse la validación por idioma, definirse umbrales por caso de uso y ejecutarse pruebas de carga y costo. Si las brechas por idioma persisten, el proceso debe regresar a preparación de datos o modelación. La arquitectura propuesta incorpora versionado, control de acceso, monitoreo, revisión humana y rollback, pero sus SLA, capacidad concurrente y costo aún deben medirse en el entorno objetivo.

Las limitaciones principales son el uso de habla leída relativamente limpia, la cobertura focalizada de ocho idiomas y 80 audios de prueba nominales, la falta de evaluación suficiente de dialectos y condiciones acústicas reales, y la ausencia de pruebas productivas de concurrencia y costo. El Gini de 0.299 reportado para la línea base aporta una señal de desigualdad en la distribución del

CER entre idiomas, pero no reemplaza el análisis desagregado ni demuestra por sí solo equidad.

Como líneas de investigación futura se propone ampliar el benchmark a idiomas y dialectos prioritarios de CLEAR e incorporar modelos *frontier* de última generación, incluidos servicios y modelos con capacidades de transcripción de audio como GPT Live y las soluciones de transcripción de Gemini, además de otras alternativas emergentes. Esta ampliación debe robustecer la investigación y abarcar más idiomas, variantes regionales y dialectos para evaluar la equidad de manera más completa. La comparación deberá distinguir reconocimiento de voz, transcripción multimodal y servicios de audio en tiempo real, ya que no necesariamente ofrecen la misma tarea ni las mismas condiciones de inferencia.

También se propone incorporar audio espontáneo y condiciones acústicas reales; realizar comparaciones pareadas con el mismo protocolo, particiones, normalización y hardware; estudiar la relación entre disponibilidad de recursos lingüísticos, fertilidad de tokenización y errores; y evaluar adaptación o *fine-tuning* cuando exista un corpus representativo, autorizado y con documentación de consentimiento y licencia. Finalmente, deberán documentarse costo por minuto, capacidad concurrente, latencia, throughput y políticas de revisión humana.

La contribución del estudio no consiste en declarar un modelo universalmente superior, sino en establecer un proceso de evaluación transparente, reproducible y sensible a la diversidad lingüística. Este proceso permite identificar brechas, explicitar incertidumbres y generar evidencia para seleccionar y mejorar tecnologías de reconocimiento de voz en contextos multilingües.

Declaración de uso de herramientas de inteligencia artificial

Durante el desarrollo de las etapas del estudio se documentó el uso de herramientas de inteligencia artificial para apoyar la estructuración de cuadernos computacionales, depuración de código, formulación de métricas y visualizaciones, y redacción técnica. En la etapa comparativa se documentó el uso de Claude y Gemini; en la etapa de optimización y selección se documentó el uso de ChatGPT. Para integrar y revisar el manuscrito también se utilizó OpenAI ChatGPT como apoyo de redacción y generación de código LaTeX. Los autores deben revisar y validar cada cifra, interpretación, referencia y decisión. La responsabilidad académica y aprobación final corresponden a los integrantes del equipo. Esta declaración debe ajustarse a las herramientas y actividades efectivamente utilizadas.

Referencias

[1] Conneau, A., Baevski, A., Richaud, A., et al. (2023). FLEURS: Few-shot learning evaluation of universal representations of speech. *IEEE Open Journal of Signal Processing, 4*, 297–305. https://doi.org/10.1109/OJSP.2023.3263882

[2] Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., & Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM, 64*(12), 86–92. https://doi.org/10.1145/3458723

[3] Graham, C., & Roll, N. (2024). Evaluating OpenAI's Whisper ASR: Performance analysis across diverse accents and speaker traits. *JASA Express Letters, 4*(2), 025206. https://doi.org/10.1121/10.0024876

[4] Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. In *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220–229). ACM. https://doi.org/10.1145/3287560.3287596

[5] Omnilingual ASR Team, Keren, G., Kozhevnikov, A., et al. (2025). Omnilingual ASR: Open-source multilingual speech recognition for 1600+ languages. *arXiv preprint arXiv:2511.09690*. https://arxiv.org/abs/2511.09690

[6] Radford, A., Kim, J. W., Xu, T., et al. (2023). Robust speech recognition via large-scale weak supervision. In *Proceedings of the 40th International Conference on Machine Learning* (Vol. 202, pp. 28492–28518). PMLR. https://proceedings.mlr.press/v202/radford23a.html

[7] Shi, X., Wang, X., Guo, Z., Wang, Y., Zhang, P., et al. (2026). Qwen3-ASR technical report. *arXiv preprint arXiv:2601.21337*. https://arxiv.org/abs/2601.21337

[8] Seamless Communication, Barrault, L., Chung, Y.-A., et al. (2023). SeamlessM4T: Massively multilingual & multimodal machine translation. *arXiv preprint arXiv:2308.11596*. https://arxiv.org/abs/2308.11596

[9] Studer, S., Bui, T. B., Drescher, C., Hanuschkin, A., Winkler, L., Peters, S., & Müller, K.-R. (2021). Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology. *Machine Learning and Knowledge Extraction, 3*(2), 392–413. https://doi.org/10.3390/make3020020

[10] Swain, M., van Zee, A. K., & Søgaard, A. (2024). On mitigating performance disparities in multilingual speech recognition. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics. https://aclanthology.org/2024.emnlp-main.323/

[11] Tabassi, E. (2023). *Artificial intelligence risk management framework (AI RMF 1.0)* (NIST AI 100-1). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.AI.100-1

[12] Thennal, D. K., James, J., Gopinath, D. P., & Ashraf, M. K. (2025). Advocating character error rate for multilingual ASR evaluation. In *Findings of the Association for Computational Linguistics: NAACL 2025*. Association for Computational Linguistics. https://aclanthology.org/2025.findings-naacl.277/

[13] van Zee, A. K., van Zee, M., & Søgaard, A. (2024). Group fairness in multilingual speech recognition models. In *Findings of the Association for Computational Linguistics: NAACL 2024* (pp. 2213–2226). Association for Computational Linguistics. https://doi.org/10.18653/v1/2024.findings-naacl.143

A. Arquitectura de referencia y controles de operación

La arquitectura descrita en la Sección 5 sintetiza el flujo lógico propuesto. Para el diseño de implementación deben completarse y aprobarse los siguientes controles:

- **Entrada:** autenticación, autorización, límites de tamaño y duración, validación MIME y protección contra archivos malformados.
- **Procesamiento:** cola con límite de concurrencia, almacenamiento temporal cifrado, borrado según política y trazabilidad de transformaciones.
- **Inferencia:** contenedor inmutable, pesos identificados por hash, GPU dimensionada con pruebas de carga y estrategia de fallback.
- **Salida:** transcripción, idioma, versión del modelo, estado y advertencia cuando el idioma o la calidad estén fuera del alcance validado.
- **Observabilidad:** p50/p95/p99, throughput, errores, profundidad de cola, VRAM y calidad diferida por idioma.
- **Gobierno:** responsable del modelo, calendario de auditoría, proceso de incidentes, rollback y revisión de cambios.

B. Ficha resumida del modelo y límites de uso

El modelo evaluado en la etapa de optimización y selección fue exclusivamente `openai/whisper-large-v3`. Greedy, Beam Search y consenso medoide son estrategias de inferencia sobre la misma arquitectura, no modelos base diferentes.

Elemento	**Contenido**
Nombre y versión	Whisper-Large-v3; registrar checkpoint y hash exactos.
Uso previsto	Transcripción asistida en idiomas y escenarios aprobados para el piloto.
Usos restringidos	Aplicaciones de alto impacto sin revisión humana; idiomas no evaluados; usos fuera de dominio.
Datos de evaluación	FLEURS y muestra focalizada; documentar particiones, licencias y representatividad.
Desempeño	Métricas macro, micro y por idioma; intervalos de confianza en la siguiente ejecución.
Sesgos y limitaciones	Variación por idioma, escritura, acento, dialecto, canal y tipo de habla.
Supervisión	Revisión humana, corrección y abstención/fallback.
Mantenimiento	Versionado, monitoreo, pruebas de regresión y revisión periódica.

C. Plan de cierre experimental previo al piloto

1. Corregir el tratamiento de audios largos y verificar que ninguna excepción se convierta silenciosamente en una transcripción vacía.

2. Reejecutar la prueba focalizada y reportar el número efectivo de audios válidos por idioma.
3. Calcular CER macro y micro, WER solo donde corresponda, Gini sobre CER por idioma y razón máximo/mínimo.
4. Obtener intervalos de confianza por remuestreo y documentar el método de agregación.
5. Comparar baseline y candidato con las mismas muestras para estimar lift pareado.
6. Medir latencia p50/p95/p99, throughput, concurrencia, memoria y costo por minuto en hardware objetivo.
7. Aprobar umbrales, idiomas habilitados, responsables, política de revisión humana y criterios de rollback.

D. Artefactos, gráficas y reproducibilidad

Repositorio: https://github.com/Luz026/VoiceBenchmark. Para reproducir el estudio deben conservarse commit, hashes de datos, configuración, dependencias, hardware, particiones y archivos CSV. Las gráficas PNG deben colocarse en la carpeta `figuras/` con los nombres indicados en el cuerpo del artículo. Antes de la entrega final, las cifras deberán regenerarse desde los notebooks y contrastarse con las tablas del manuscrito.