

Tecnológico de Monterrey

# Avance 01. Análisis exploratorio de datos

Alejandro Agustín Ahedo González - A01797242

Andrés Roberto Osuna González - A01796264

Sandra Luz Cervantes Espinoza - A01796937

04 de octubre del 2026

Equipo 57 - Proyecto Integrador (Gpo 10)

Profesores: Dra. Liliana Ibeth Barbosa Santillán, Dra. Grettel Barceló Alonso y Dr. Luis Eduardo Falcón Morales

# Avance 1: Análisis Exploratorio de Datos (EDA) y Preprocesamiento del Corpus FLEURS en el Marco de Equidad Multilingüe

El presente documento consolida la fase de análisis exploratorio de datos (EDA) y la arquitectura del pipeline de preprocesamiento para el proyecto de investigación aplicada desarrollado en colaboración entre el equipo del Tecnológico de Monterrey y la coalición internacional CLEAR (Coalition for Language Equity in AI Research). El objetivo central de esta entrega técnica consiste en caracterizar exhaustivamente las propiedades acústicas y textuales del corpus FLEURS, identificar las patologías de datos intrínsecas en las transcripciones de referencia, fundamentar matemática y operativamente la reducción dimensional de la señal de audio y diagnosticar el sesgo estructural que sufren las métricas tradicionales de evaluación ASR frente a familias lingüísticas no occidentales. La totalidad de los scripts, notebooks de prueba y artefactos de software generados en esta etapa están integrados de forma totalmente reproducible en el repositorio oficial del proyecto: Github VoiceBenchmark Equipo 57.

Nuestro proyecto realizado en Colab, donde se presenta el análisis se encuentra en: VoiceBenchmark Analysis

## 1. Contexto del Corpus y Particionamiento Experimental

El conjunto de datos seleccionado para este estudio es FLEURS (Few-shot Learning Evaluation of Universal Representations of Speech), un benchmark multimodal derivado de las traducciones paralelas del corpus FLoRes-101. FLEURS fue concebido específicamente para evaluar las capacidades de representación universal del habla en tareas complejas como el reconocimiento fonético, la identificación automática de idioma (LID) y la traducción de habla a texto (STT).

### Especificaciones Técnicas del Corpus FLEURS

**Nombre completo:** FLEURS (*Few-shot Learning Evaluation of Universal Representations of Speech*)

**Organización creadora:** Google (Derivado y alineado con las traducciones paralelas del corpus multimodal *FLoRes-101*) se puede consultar en https://huggingface.co/datasets/google/fleurs.

**Licencia de uso:** CC-BY-4.0 (Dominio público para investigación y desarrollo).

**Propósito principal:** Diseñado como un benchmark estandarizado multilingüe para evaluar modelos de representación universal del habla en tareas subyacentes como:

- Reconocimiento Automático de Habla (ASR - *Automatic Speech Recognition*).
- Identificación de Idiomas (LID - *Language Identification*).
- Traducción de Habla a Texto (STT - *Speech-to-Text Translation*).
- Tareas de aprendizaje de pocas muestras (*Few-shot learning*).

### Dimensión y Estructura del Dataset

Cobertura lingüística: Soporte oficial para más de 100 idiomas y dialectos distribuidos globalmente a lo largo de diversos troncos lingüísticos y familias de lenguas (incluyendo lenguas de recursos bajos y de alta representación).

Volumen de audio: Aproximadamente sólo audio de alta fidelidad recolectado de locutores nativos, con un total agregado que supera las cientos de horas de grabación de voz limpia.

### Particiones Oficiales estándar (Splits):

- Train (Entrenamiento): Conjunto amplio de adaptabilidad (varía por idioma, típicamente con miles de muestras por lengua).
- Validation (Validación): Subconjunto de ajuste de hiperparámetros.
- Test (Prueba): Conjunto estrictamente controlado utilizado para las evaluaciones de rendimiento (líneas base y validación empírica).

### Estructura de Datos y Formato de Registro

Cada instancia dentro del dataset en plataformas como Hugging Face se estructura mediante los siguientes metadatos clave:

- `id`: Identificador único de la muestra.
- `audio`: Objeto de audio decodificado que contiene la ruta del archivo `.wav` (frecuencia de muestreo estándar de alta calidad, comúnmente a 16 kHz), la matriz de datos y la tasa de muestreo.
- `transcription`: Transcripción ortográfica oficial limpia y normalizada del texto pronunciado.
- `raw_transcription`: Transcripción en bruto con puntuaciones y mayúsculas originales correspondientes al texto de FLoRes.
- `gender`: Etiqueta de clase que indica el género demográfico del locutor (`male` / `female`).
- `lang_id` y `language`: Identificador del idioma y nombre legible.
- `lang_group_id`: Agrupación macrolingüística o tronco geográfico/histórico (ej. *sub_saharan_african_ssa*, *western_europe*, etc.).

Para esta fase inicial de validación empírica y establecimiento de líneas base, se construyó un subconjunto enfocado a partir de la partición oficial de prueba (*test split*) del corpus multilingüe **Google FLEURS**, el cual abarca un total de **103 lenguas** estratégicamente seleccionadas por su representatividad en diversos troncos lingüísticos y su amplia diversidad de sistemas de escritura.

Con el propósito de garantizar la repetibilidad estadística del muestreo y asegurar comparaciones parejas entre arquitecturas, se fijó una semilla pseudoaleatoria determinista

(SEED = 42). Se extrajeron exactamente cincuenta grabaciones por idioma mediante un flujo optimizado en memoria (*streaming*), consolidando un corpus balanceado de 5,150 archivos de audio vinculados a sus transcripciones ortográficas verificadas por hablantes nativos y a sus metadatos operacionales. Este corpus controlado permite someter a prueba las capacidades de generalización de arquitecturas de IA líderes en el estado del arte bajo condiciones idénticas de ingestión, tales como OpenAI Whisper-Large-v3, Meta SeamlessM4T v2, Alibaba Qwen3-ASR (0.6B de parámetros) y modelos de reconocimiento de voz multilingüe de gran escala.

## 2. Análisis Univariante y Propiedades Estadísticas de las Variables

La revisión física de los archivos de audio confirma que todos se presentan en formato WAV de un solo canal, con una velocidad de muestreo constante de 16,000 hercios. En la práctica, esto significa que cada segundo de sonido se divide en 16,000 valores numéricos con decimales, ubicados en un rango de amplitud entre -1.0 y 1.0.

Al medir la duración de los 5,150 audios del conjunto de prueba, aplicando el filtro establecido entre 1.0 y 15.0 segundos, se observa que los archivos reales se mueven entre los 3.0 y los 10.2 segundos. El promedio de duración es de 5.4 segundos, el valor que queda justo en el centro es de 5.1 segundos, y la variación estándar es de 1.8 segundos. Los datos muestran una leve tendencia a prolongarse hacia los valores más altos, concentrando la mayoría de los audios entre los 4 y los 7 segundos. Este tamaño es muy adecuado para alimentar las redes neuronales de procesamiento de voz sin saturar la memoria de la tarjeta gráfica ni generar espacios vacíos innecesarios.

En cuanto a las variables categóricas, el diseño de la muestra mantiene un control estricto. La variable de idioma cuenta con 103 opciones diferentes, distribuyendo equitativamente cincuenta muestras por cada lengua. Sobre el género de la voz, se manejan dos categorías (masculino y femenino) divididas equilibradamente en el grupo de prueba. Este cuidado metodológico evita que las diferencias naturales en el tono de voz de los hablantes afecten la dificultad de reconocimiento entre los distintos idiomas.

En la parte del texto, se nota una gran diferencia según el sistema de escritura de cada lengua. En los idiomas que usan el alfabeto latino, la longitud promedio de las transcripciones va de 15 a 22 palabras por frase, lo que representa entre 85 y 130 caracteres. Por el contrario, los idiomas con escrituras complejas y alta densidad, como el japonés que combina kanji y kana, no utilizan espacios en blanco para separar las palabras. Esto produce secuencias seguidas de 40 a 80 caracteres por oración, lo que cambia de forma notable la manera en que se cuentan y evalúan las palabras.

## 3. Diagnóstico de Problemas en los Datos y Detección de Anomalías

La verificación de integridad del subconjunto confirmó que no hay valores nulos ni registros dañados en los campos estructurales principales (como el identificador, el audio, las transcripciones y los metadatos de género e idioma). Todos los archivos de audio se decodificaron correctamente, sin pérdida de fragmentos ni diferencias en la velocidad de muestreo. Sin embargo, el análisis exploratorio dejó ver dos problemas importantes al evaluar directamente los modelos: las pequeñas diferencias en la escritura de los textos y el fallo numérico de la métrica de tasa de error por palabra (WER) al evaluar lenguas que no usan espacios.

El primer problema tiene que ver con las diferencias tipográficas en los textos de referencia. Las transcripciones originales presentan detalles variados en puntuación, uso de mayúsculas, símbolos juntos y tipos de codificación. Por ejemplo, en el registro en español con la clave 1811, la referencia oficial indica «el 802.11n estándar funciona tanto en frecuencias de 2.4ghz como 5.0ghz», mientras que el modelo Whisper predice «El 802.11n estándar funciona en frecuencias de 2.4 GHz como 5.0 GHz.». Si no se aplica una etapa de normalización, las herramientas que calculan los errores penalizan las mayúsculas iniciales, los espacios entre los números y las unidades ( «ghz» frente a «GHz») y los puntos finales. Esto eleva la tasa de error de forma artificial, aunque en la práctica el reconocimiento del sonido haya sido perfecto.

El segundo hallazgo, de gran importancia para lograr una evaluación justa en inteligencia artificial, es la falla metodológica del WER al aplicarse al idioma japonés. En lenguas occidentales que sí separan las palabras con espacios, Whisper-Large-v3 obtuvo tasas de error muy bajas: 2.76% en italiano, 3.08% en portugués, 3.17% en alemán, 3.49% en español y 3.50% en inglés. No obstante, al calcular esa misma métrica en japonés, el error de Whisper-Large-v3 subió drásticamente al 74.99%, mientras que SeamlessM4T alcanzó un 78.02%, Qwen3-ASR un 80.10% y Omnilingual ASR CTC llegó al 115.16%.

Un error cercano o superior al cien por ciento sugeriría que los modelos no entendieron nada del audio. Sin embargo, al revisar de manera visual las predicciones frente a las referencias, se comprueba que los modelos reproducen el contenido hablado con un nivel de acierto altísimo. La razón matemática de este colapso ocurre porque las librerías tradicionales de evaluación (como jiwer) están diseñadas para separar las palabras usando únicamente el espacio en blanco. Como el japonés no utiliza espacios, el algoritmo toma toda la oración de cincuenta o más caracteres como si fuera una sola palabra gigante. Por esta razón, si el modelo cambia un solo carácter, sustituye un kanji por su equivalente en kana o agrega un signo de puntuación, la distancia de edición penaliza la oración completa, arruinando la utilidad del WER como herramienta de diagnóstico.

## 4. Operaciones de Preprocesamiento, Normalización y Reducción Dimensional

Para solucionar los problemas encontrados durante el análisis exploratorio, se creó un proceso estandarizado que limpia las transcripciones, unifica las señales de audio y adapta la métrica de evaluación a la forma en que se escribe cada lengua.

En la parte del texto, se aplicó una función llamada normalize_text a las referencias y a las predicciones de los modelos. Esta rutina unifica los caracteres Unicode bajo el estándar NFKC, cambia todo a minúsculas, elimina signos y símbolos con expresiones regulares, y quita los espacios sobrantes.

En la parte del audio, el proceso ajusta cualquier archivo de entrada. Si tiene varios canales, se convierte en uno solo y, mediante funciones de interpolación digital, se fija una velocidad exacta de 16,000 muestras por segundo. Para que los modelos generen sus representaciones internas, como los espectrogramas de Mel en Whisper y SeamlessM4T o las tramas en arquitecturas CTC.

En el aspecto metodológico, se cambió el uso del WER por el Character Error Rate (CER) para el japonés y otros idiomas sin espacios. El CER calcula los errores contando las letras individuales que fallan entre el total de caracteres del texto original. Al volver a evaluar las muestras de japonés con CER, el error de Whisper-Large-v3 bajó del 74.99% al 6.21%, un dato muy cercano al 5.3% que reportó OpenAI en su artículo original para FLEURS. Con esta corrección, el error de SeamlessM4T quedó en 9.47%, el de Qwen3-ASR en 10.06% y el de Omnilingual ASR CTC en 22.16%. Esto demuestra que el CER es la métrica adecuada para evaluar lenguas sin separación de palabras.

| Idioma | Tronco / Escritura | Whisper Large-v3 (WER) | SeamlessM4T v2 (WER) | Qwen3-ASR 600M (WER) | Omnilingual CTC (WER) |
|---|---|---|---|---|---|
| **Italiano** | Romance / Latina | 2.76% | 4.81% | 7.72% | 13.87% |
| **Portugués** | Romance / Latina | 3.08% | 8.40% | 5.05% | 14.12% |
| **Alemán** | Germánica / Latina | 3.17% | 5.96% | 5.62% | 16.02% |
| **Español** | Romance / Latina | 3.49% | 8.18% | 6.46% | 14.12% |
| **Inglés** | Germánica / Latina | 3.50% | 8.26% | 5.92% | 19.06% |
| **Ruso** | Eslava / Cirílica | 3.77% | 7.47% | 11.62% | 27.75% |
| **Holandés** | Germánica / Latina | 6.82% | 10.23% | 14.91% | 24.61% |
| **Francés** | Romance / Latina | 7.18% | 9.17% | 10.34% | 26.43% |
| **Hindi** | Indoaria / Devanagari | 15.07% | 7.15% | 8.76% | 16.95% |
| **Japonés*** | Japónica / Kanji-Kana | 6.21% (CER) | 9.47% (CER) | 10.06% (CER) | 22.17% (CER) |

Tabla 1. Comparativa de desempeño (WER y CER) entre arquitecturas ASR en el corpus FLEURS.

*Nota: Para el idioma japonés se reporta la métrica CER (Character Error Rate) en sustitución del WER debido a la ausencia natural de espacios entre palabras.

El comportamiento general de las arquitecturas sobre el corpus demuestra patrones estadísticos claros. Whisper-Large-v3 dominó la prueba en la mayoría de los idiomas evaluados, registrando la menor tasa de error en lenguas con alfabeto latino y cirílico. No obstante, este nivel de precisión conlleva un costo computacional apreciable, registrando una latencia promedio de 2.51 segundos por cada inferencia de audio.
Por otra parte, Meta SeamlessM4T v2 demostró un desempeño superior en hindi, reduciendo el error al 7.15% frente al 15.07% de Whisper. Además de su eficacia con esta escritura, SeamlessM4T exhibió una latencia promedio de 1.44 segundos por muestra, resultando más rápido que Whisper. Esto confirma que su estrategia de preentrenamiento favorece la extracción de características en lenguas con alta riqueza morfológica.

El modelo Alibaba Qwen3-ASR sostuvo un rendimiento equilibrado en todas las categorías, promediando una latencia de 1.85 segundos por muestra. Por último, Omnilingual ASR CTC destacó como la opción de mayor velocidad operativa con un tiempo de procesamiento de apenas 73 milisegundos por audio. Sin embargo, su arquitectura genera una brecha sustancial en precisión con un error elevado en varios idiomas de la prueba debido a la carencia de un modelo de lenguaje integrado que corrija desalineaciones fonéticas contextualmente.

## 6. Correlación Cruzada: Tokenizer Tax y Descomposición del Error Acústico

Un aporte clave de esta investigación consiste en vincular empíricamente el error de reconocimiento de voz observado en FLEURS con el indicador de sesgo económico en texto denominado Tokenizer Tax, documentado en los estudios de CLEAR sobre el corpus FLORES-200. Las investigaciones en tokenización han demostrado que lenguas como el hindi sufren una penalización computacional sistemática, requiriendo un mayor número de tokens que el inglés para codificar la misma carga semántica. Esta fragmentación excesiva ocurre porque los vocabularios de los tokenizadores tradicionales contienen muy pocas subpalabras dedicadas al alfabeto Devanagari.

Al cruzar dicho indicador con las tasas de error acústico obtenidas, se observa una clara correspondencia: el hindi fue el idioma con mayor degradación en el modelo Whisper-Large-v3 (15.07% de WER), en fuerte contraste con los idiomas de origen latino que presentan bajos índices de penalización de tokenización y que alcanzaron tasas de error muy reducidas (por debajo del 3.5%). Esta correlación indica que la infrarrepresentación de una lengua en el espacio léxico textual de los modelos fundacionales tiende a propagarse hacia los codificadores de audio, justificando la necesidad de incorporar el índice de recursos como variable explicativa en las fases posteriores del proyecto.

## 7. Conclusiones Fundacionales y Hoja de Ruta Experimental

El desarrollo de este primer avance experimental aporta conclusiones de profunda trascendencia metodológica y técnica, consolidando los pilares para el escalamiento y la rigurosidad científica del proyecto en colaboración con el equipo del Tecnológico de Monterrey y CLEAR:

Inadecuación metodológica del WER como estándar universal: La métrica de tasa de error por palabra (*Word Error Rate* - WER) demostró ser inviable en contextos multilingües heterogéneos. Su dependencia estricta del espacio en blanco colapsa al evaluarse en lenguas aglutinantes o con sistemas de escritura sin delimitadores léxicos (como el japonés), inflando artificialmente la tasa de error por encima del 100%. Por ello, resulta indispensable adoptar el *Character Error Rate* (CER) para obtener diagnósticos reales sobre la capacidad de decodificación de las arquitecturas.

Requisito imperativo de la normalización textual y acústica: La integración de un *pipeline* estricto de normalización Unicode bajo el estándar NFKC y la limpieza sistemática de puntuación y símbolos elimina discrepancias puramente superficiales. Omitir esta etapa provoca que diferencias estéticas —como mayúsculas situacionales, símbolos alfanuméricos pegados o espacios entre unidades físicas— incrementen de forma engañosa el error evaluado entre 2 y 5 puntos porcentuales, enmascarando el verdadero rendimiento del modelo.

Comportamiento diferencial y especialización de las arquitecturas: El análisis de línea base confirma la alta solidez de *Whisper-Large-v3* en lenguas de troncos romances, germánicos y eslavos, al tiempo que resalta la superioridad de *SeamlessM4T v2* al procesar escrituras indoarias complejas como el Devanagari (Hindi), donde reduce sustancialmente el margen de error. Asimismo, se documentó el balance operativo de *Qwen3-ASR* y la velocidad extrema de *Omnilingual ASR CTC*, limitada críticamente por la ausencia de un modelo de lenguaje integrado para la corrección contextual.

**Hoja de Ruta Experimental**

Validados los procedimientos de ingesta, filtrado determinista mediante semillas pseudoaleatorias (`SEED = 42`) y normalización en el repositorio oficial **VoiceBenchmark**, las siguientes fases de la investigación contemplan:

1. **Escalamiento del Corpus:** Extender la evaluación analítica hacia la totalidad de los 103 idiomas que componen el corpus FLEURS completo, garantizando la paridad estadística y la representación equilibrada de troncos lingüísticos minoritarios y de baja provisión de recursos.
2. **Evaluación con Modelos Multimodales Nativos:** Incorporar pruebas comparativas utilizando las API de arquitecturas multimodales de última generación (tales como Gemini y GPT Audio), lo que permitirá contrastar el rendimiento de los sistemas ASR especializados tradicionales frente a las nuevas fronteras de los modelos unificados de voz y lenguaje.
3. **Optimización del Análisis de Sesgo:** Profundizar en el estudio de la correlación cruzada entre el *Tokenizer Tax* y la degradación acústica, estableciendo el índice de recursos web (*resourceness*) como una variable explicativa clave en la equidad de la inteligencia artificial conversacional.

## Referencias Bibliográficas


### Datasets y Benchmarks Multilingües

- Conneau, A., Ma, M., Khanuja, S., Zhang, Y., Axmed, C., Riesa, J., Rivera, R., & Bapna, A. (2022). FLEURS: Few-shot Learning Evaluation of Universal Representations of Speech. arXiv preprint arXiv:2205.12446. https://doi.org/10.48550/arXiv.2205.12446
- Goyal, N., Gao, C., Chaudhary, V., Riesa, J., Agarwal, A., Ju, C., Guzmàn, P., ... & Guzman, F. (2022). The FLORES-101 evaluation benchmark for low-resource multilingual machine translation. Transactions of the Association for Computational Linguistics, 10, 522–538. https://doi.org/10.1162/tacl_a_00474
- NLLB Team, Costa-jussà, M. R., Cross, J., Onali, C., Zheng, P., Ko, M. R., ... & Guzman, F. (2022). No Language Left Behind: Scaling Human-Centered Machine Translation. arXiv preprint arXiv:2207.04672. https://doi.org/10.48550/arXiv.2207.04672

### Arquitecturas de Modelos ASR y Voz

- Barrault, L., Chung, Y. A., Meglioli, M. C., Dale, D., Dong, N., Duquenne, P. A., ... & Zhou, Y. (2023). SeamlessM4T: Massively Multilingual & Multimodal Machine Translation. arXiv preprint arXiv:2308.11596. https://doi.org/10.48550/arXiv.2308.11596
- Chu, Y., Xu, J., Zhou, L., Yang, G., Zhang, S., Yan, Z., Chang, C., & Zhou, J. (2023). Qwen-Audio: Advancing Universal Audio Understanding Capabilities. arXiv preprint arXiv:2311.07919. https://doi.org/10.48550/arXiv.2311.07919
- Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2023). Robust speech recognition via large-scale weak supervision. In Proceedings of the 40th International Conference on Machine Learning (PMLR 202: 28492–28518). https://proceedings.mlr.press/v202/radford23a.html

### Métricas, Normalización y Herramientas de Procesamiento

- Davis, M., & Whistler, K. (2023). Unicode Standard Annex #15: Unicode Normalization Forms. The Unicode Consortium. https://www.unicode.org/reports/tr15/
- Morris, A. C., Maier, V., & Green, P. (2004). From WER and RIL to MER and WIL: Improved evaluation measures for connected speech recognition. In Proceedings of INTERSPEECH 2004 - 8th International Conference on Spoken Language Processing (pp. 2765–2768). https://doi.org/10.21437/Interspeech.2004-706
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... & Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. Advances in Neural Information Processing Systems, 32, 8024–8035.

**Equidad Lingüística y Tokenización**


- Ahia, O., Kumar, S., Gonen, H., Guzmàn, P., & Tsvetkov, Y. (2023). Do All Languages Cost the Same? Tokenization in the Era of Commercial Large Language Models. arXiv preprint arXiv:2305.13707. https://arxiv.org/abs/2305.13707
- Petrov, A., La Malfa, E., Toro, P., & Shadbolt, N. (2024). Language model tokenizers introduce unfairness across languages and scripts. Nature Machine Intelligence, 6(3), 291–299. https://www.researchgate.net/publication/397956982_Genetic-exposome_axis_orchestrates_cardiac_motion_patterns