

Tecnológico de Monterrey

Avance 2. Ingeniería de características y preparación de Datos (CRISP-ML)

Alejandro Agustín Ahedo González - A01797242

Andrés Roberto Osuna González - A01796264

Sandra Luz Cervantes Espinoza - A01796937

11 de octubre del 2026

Equipo 57 - Proyecto Integrador (Gpo 10)

Profesores: Dra. Liliana Ibeth Barbosa Santillán, Dra. Grettel Barceló Alonso y Dr. Luis Eduardo Falcón Morales

Datos del Proyecto y del Equipo

Título del Proyecto	Benchmarking de voz multimodal
Palabras Clave	Gen AI, Voz, LLM, Multilingual, Low-Resource Languages, ASR, FLEURS
Integrantes del Equipo	• Alejandro Agustín Ahedo González (A01797242) • Andrés Roberto Osuna González (A01796264) • Sandra Luz Cervantes Espinoza (A01796937)
Profesorado Asesor	• Dra. Liliana Ibeth Barbosa Santillán
Organización Receptora	CLEAR (Coalition for Language Equity in AI Research)
Sponsors / Patrocinadores	• Dr. Juan Arturo Nolazco Flores (Director del Hub de Ciencia de Datos - jnolazco@tec.mx) • Dr. Francisco Guzmán (Head of Research at Handshake - paco@joinhandshake.com)
Repositorio de Código	https://github.com/Luz026/VoiceBenchmark

1. Ingeniería de Características (Feature Engineering) 2
1.1 Operaciones y Transformaciones Aplicadas 3
Remuestreo y Estandarización de Frecuencia (16 kHz) 3
Reducción de Canales (Conversión a Canal Mono) 3
Casting de Tipo de Datos y Normalización Numérica (float32) 3
Padding Dinámico y Empaquetado por Lotes (Batching) 3
Transformación Acústica a Espectrogramas Mel / Caracterización Espectral 3
Normalización Lingüística y Limpieza de Texto 4
1.2 Selección y Extracción de Características 4
Selección de datos y filtrado estratificado 4
Extracción de Características Acústicas Profundas 4
2. Conclusiones de la Fase de "Preparación de Datos" (Contexto CRISP-ML) 4
Calidad de Datos y Reproducibilidad (Data Quality) 5
Gestión Eficiente de Recursos e Infraestructura 5
Mitigación de Sesgo Lingüístico en las Métricas 5
Aceptación para la Fase de Modelación 5
5. Referencias Bibliográficas 5
6. Anexos 6
Anexo A: Convenio de Privacidad y Colaboración de Proyecto Integrador 6
Anexo B: Repositorio Oficial y Licencias de Software 6

1. Ingeniería de Características (Feature Engineering)

En el dominio del procesamiento de lenguaje hablado (Speech/ASR), la ingeniería de características comprende tanto el acondicionamiento de las señales de audio crudas como la normalización del texto de las transcripciones.

1.1 Operaciones y Transformaciones Aplicadas

Remuestreo y Estandarización de Frecuencia (16 kHz)

Técnica: Conversión de la tasa de muestreo de todos los clips de audio a 16,000 Hz (16 kHz).

Justificación: Las arquitecturas de redes neuronales de los modelos ASR evaluados (*Transformers*, *Conformer*, *CTC*) fueron preentrenadas con espectrogramas extraídos a 16 kHz. Mantener frecuencias dispares alteraría la escala temporal y espectral de las convoluciones iniciales.

Reducción de Canales (Conversión a Canal Mono)

Técnica: Promedio ponderado de canales para señales de audio estéreo o multicanal: `audio = np.mean(audio, axis=0)`.

Justificación: Estandariza la entrada a una señal unidimensional (1D), reduciendo a la mitad el volumen de datos en GPU sin perder componentes fonéticas críticas.

Casting de Tipo de Datos y Normalización Numérica (`float32`)

Técnica: Conversión explícita de los arreglos numéricos de la señal a punto flotante de 32 bits (`np.float32`).

Justificación: Previene errores de desbordamiento (*underflow/overflow*) durante el cálculo del espectrograma Mel y asegura la compatibilidad con el cómputo de media precisión (`float16`) en la GPU.

Padding Dinámico y Empaquetado por Lotes (Batching)

Técnica: Alineación de longitud de secuencias mediante relleno de ceros (*padding*) coordinado por los objetos `AutoProcessor`.

Justificación: Permite procesar múltiples audios de duración variable en un solo tensor matricial, maximizando la paralelizabilidad y el rendimiento en memoria VRAM.

Transformación Acústica a Espectrogramas Mel / Caracterización Espectral

Técnica: Conversión de la señal temporal en el dominio de la frecuencia mediante la transformación a espectrograma de log-Mel (realizada en la capa de preprocesamiento del pipeline).

Justificación: La escala Mel imita la percepción logarítmica del oído humano frente a las frecuencias, destacando los formantes de la voz e ignorando variaciones no relevantes.

Normalización Lingüística y Limpieza de Texto

Técnica: Preservación de signos vocálicos en lenguas índicas y del sudeste asiático (Hindi, Bengali, Thai, etc.). Eliminación de espacios en blanco artificiales en lenguas con escritura continua (Chino, Japonés, Tailandés, Laosiano, Jemer, Birmano).

Justificación: Correcciones fundamentales para evitar distorsiones en las métricas de evaluación. En scripts continuos, los espacios inflaban de manera irreal el *Character Error Rate* (CER) y el *Word Error*

Rate (WER); por otro lado, la remoción indiscriminada de diacríticos alteraba el **significado sintáctico.**

1.2 Selección y Extracción de Características

Selección de datos y filtrado estratificado

- Muestreo Determinista de Tamaño Fijo ($N = 50$):

Método: Muestreo aleatorio controlado con semilla SEED = 42 para extraer exactamente 50 muestras por idioma (total de 5,100 clips de audio).
Justificación: Garantiza un conjunto de prueba balanceado entre lenguas de altos y bajos recursos, manteniendo la representatividad estadística y limitando el costo computacional.

- Alineación y Mapeo de Códigos de Idioma:

Método: Filtrado y remapeo de identificadores de idioma (WHISPER_FIX, QWEN_FIX). Por ejemplo, mapear cmn a zh, o fil a tl.
Justificación: Previene fallos de ejecución en los tokenizadores y codificadores de los modelos que no utilizan la convención estándar BCP-47 de FLEURS.

Extracción de Características Acústicas Profundas

Representaciones Latentes (Deep Embeddings):
En lugar de aplicar métodos tradicionales de reducción de dimensionalidad tabular (como PCA, ANOVA o Chi-cuadrado), los preprocesadores y capas convolucionales primarias de las redes neuronales profundas (p. ej., `omniASR-CTC-300M`, `Qwen3-ASR`, `Whisper`) actúan como extractores automáticos de características.

Justificación: La señal de audio cruda contiene miles de puntos por segundo. Las redes convolucionales reducen la dimensionalidad temporal a vectores de características con alta densidad de información fonética.

2. Conclusiones de la Fase de "Preparación de Datos" (Contexto CRISP-ML)

Bajo el marco de la metodología **CRISP-ML(DQ)** (*Cross Industry Standard Process for Machine Learning with Data Quality*), se destacan las siguientes conclusiones sobre la fase de preparación de datos:

Calidad de Datos y Reproducibilidad (Data Quality)

La implementación de un sistema de almacenamiento en caché persistente (`pickle` en Google Drive) combinado con muestreo aleatorio fijado mediante semilla (`SEED=42`) aseguró la reproducibilidad exacta del pipeline. Esto redujo el tiempo de preparación de 106 minutos a

menos de 1 minuto en ejecuciones posteriores.

Gestión Eficiente de Recursos e Infraestructura

La estandarización de la señal (16 kHz, mono, `float32`) junto con el control dinámico de los lotes (*batch size*) previno errores de memoria GPU (*Out Of Memory*), optimizando el rendimiento de inferencia sin perder precisión acústica.

Mitigación de Sesgo Lingüístico en las Métricas

La fase de normalización de texto específica por familia de lenguajes resultó determinante para garantizar la validez del benchmarking. De no haber corregido el manejo de espacios y diacríticos, las métricas WER y CER habrían mostrado penalizaciones falsas no atribuibles al desempeño real del modelo ASR.

Aceptación para la Fase de Modelación

El conjunto de datos preparado cumple con los criterios de calidad, integridad y rendimiento requeridos para continuar de forma secuencial hacia las fases de inferencia, benchmarking y evaluación comparativa.

5. Referencias Bibliográficas

Conforme a los lineamientos del estilo **APA (7.ª edición)**, se consignan las fuentes primarias que fundamentan esta propuesta:

Barrault, L., Chung, Y. A., Meglioli, M. C., Prasad, R., Radford, A., & Thomas, S. (2023). *SeamlessM4T: Massively multilingual and multimodal machine translation*. arXiv preprint arXiv:2308.11596. https://doi.org/10.48550/arXiv.2308.11596

Chu, Y., Xu, J., Zhou, X., Yang, Z., Zhang, S., Yan, R., Chang, Y., Ye, J., Yuan, H., Li, Z., Liu, S., Lu, C., Liu, X., Zhou, J., & Zhou, J. (2023). *Qwen-Audio: Advancing universal audio understanding capabilities*. arXiv preprint arXiv:2311.07919. https://doi.org/10.48550/arXiv.2311.07919

Conneau, A., Baevski, A., Riva, A., Tao, F., Zhang, Y., Yu, Z., Chan, C., Tang, C., Wang, A., Lin, Y., Yang, M., & LeCun, Y. (2023). FLEURS: Few-shot learning evaluation of universal representations of speech. *IEEE Open Journal of Signal Processing*, 4, 297–305. https://doi.org/10.1109/OJSP.2023.3263882

Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2023). Robust speech recognition via large-scale weak supervision. In *Proceedings of the 40th International Conference on Machine Learning* (Vol. 202, pp. 28492–28518). PMLR. https://proceedings.mlr.press/v202/radford23a.html

Studer, S., Bui, T. B., Amer, C., Nguyen, P. T., & Buxmann, P. (2021). Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology. *Machine Learning with*

Applications, 6, Article 100128. https://doi.org/10.1016/j.mlwa.2021.100128

Zhang, Y., Han, W., Qin, J., Wang, Y., Bapna, A., Chen, Z., Li, B., Lu, L., Rybach, D., Yu, A. W., Chen, C. C., Zhang, Y., Shen, J., Zhou, Y., Polosukhin, I., & Wu, Y. (2023). *Google USM: Scaling automatic speech recognition for 100+ languages*. arXiv preprint arXiv:2303.01037. https://doi.org/10.48550/arXiv.2303.01037

6. Anexos

Anexo A: Convenio de Privacidad y Colaboración de Proyecto Integrador

Se incluye la carta de conformidad y convenio de colaboración firmado digitalmente por los *sponsors* del proyecto (Dr. Juan Arturo Nolazco Flores y Dr. Francisco Guzmán) y los alumnos integrantes del **Equipo 57**. Debido a la comisión académica del Dr. Francisco Guzmán (retorno programado para el 11 de octubre), el documento consolidado con las firmas de ambas partes se adjunta formalmente en este apartado.

Anexo B: Repositorio Oficial y Licencias de Software

El repositorio de código fuente, los archivos de preprocesamiento, la suite de pruebas y los pipelines automatizados de evaluación se encuentran alojados públicamente en GitHub:

- **Repositorio oficial:** https://github.com/Luz026/VoiceBenchmark
- **Licencia de código:** MIT License.
- **Licencia de datos:** CC-BY-4.0 (conforme a los términos de distribución del corpus FLEURS de Google).