HACIA LA EQUIDAD LINGÜÍSTICA EN TECNOLOGÍAS DE VOZ

Benchmark multimodal de reconocimiento automático del habla

Resumen ejecutivo para CLEAR

Equipo: 57 – Proyecto Integrador, Grupo 10
Integrantes: Alejandro Agustín Ahedo González; Andrés Roberto Osuna González; Sandra Luz Cervantes Espinoza
Organización receptora: CLEAR (Coalition for Language Equity in AI Research)
Asesoría: Dra. Liliana Ibeth Barbosa Santillán
Fecha: 11 de noviembre de 2026

1. La decisión ejecutiva

La equidad lingüística en inteligencia artificial exige que las personas puedan interactuar con estas tecnologías en sus idiomas sin que la calidad del servicio dependa injustificadamente de cuánto está representada su lengua en los datos digitales.

Cuando un sistema de reconocimiento automático del habla funciona mejor para unos idiomas que para otros, reproduce una barrera de acceso: algunas comunidades reciben transcripciones más útiles, mientras otras enfrentan más errores, menor confiabilidad y una experiencia tecnológica desigual. Los promedios globales pueden ocultar esas diferencias.

CLEAR (Coalition for Language Equity in AI Research) sitúa la equidad entre idiomas como un problema que debe medirse y abordarse con evidencia. En su análisis sobre la desigualdad de tokenización, CLEAR muestra cómo determinadas decisiones técnicas pueden imponer costos desiguales a distintas lenguas [1].

Ese análisis se centra en tokenizadores de modelos de lenguaje, buscando que los usuarios de IA puedan hacer visibles las disparidades lingüísticas y aplicar una evaluación transparente al reconocimiento automático del habla (ASR).

El proyecto construye un flujo reproducible para comparar sistemas ASR, medir sus errores por idioma y aportar evidencia para seleccionar y mejorar tecnologías de voz con un criterio explícito de equidad lingüística. Utiliza el corpus abierto FLEURS, diseñado como benchmark multilingüe para investigación en tecnologías del habla [2], un pipeline de normalización acústica y textual y métricas complementarias WER y CER.

El objetivo es identificar qué idiomas están mejor o peor atendidos bajo condiciones comparables y qué aspectos requieren más datos, evaluación o adaptación.

2. Evidencia técnica disponible

En la evaluación final, la configuración seleccionada fue `openai/whisper-large-v3` con decodificación base (greedy), perteneciente a la familia de modelos de reconocimiento multilingüe de voz descrita por Radford et al. [3].

Sobre el conjunto de prueba reservado de ocho idiomas, el notebook reporta los siguientes resultados:

4.91 %	8.03 %	33.75 %	1.491 s
CER en prueba	**WER en prueba**	**Coincidencia exacta**	**Latencia promedio**
Ocho idiomas	Idiomas con espacios	Texto normalizado	Por audio

La búsqueda Beam Search con cinco haces obtuvo mejores cifras en validación (CER 2.96 % y WER 4.01 %), pero la selección final priorizó el equilibrio observado entre error y tiempo en prueba, no el resultado de validación por sí solo.

Implicación para la equidad lingüística.

Estos resultados constituyen una primera línea de evidencia, no una demostración de equidad entre idiomas.

El conjunto final cubre ocho idiomas y el tamaño de prueba es reducido. Por ello, no permite afirmar que el sistema trate de manera justa a todas las comunidades lingüísticas ni extrapolar el desempeño a lenguas no evaluadas. Sí demuestra por qué es necesario medir y reportar los errores por idioma y elegir métricas compatibles con cada sistema de escritura.

El CER permite comparar sistemas de escritura sin espacios; el WER debe reservarse para idiomas en los que la segmentación por palabras sea válida.

En el avance exploratorio, el uso de CER corrigió la lectura del japonés: Whisper pasó de un WER artificialmente elevado de 74.99 % a un CER de 6.21 %. Esto ilustra por qué la métrica debe adaptarse a la lengua. Investigaciones sobre evaluación de ASR en japonés también documentan dificultades relacionadas con segmentación y variantes ortográficas [5].

Los resultados respaldan un piloto controlado de evaluación y transcripción asistida, pero no justifican todavía un despliegue productivo sin validación adicional.

3. Contribución a la equidad lingüística y valor para CLEAR

La contribución central para CLEAR es aportar un instrumento reproducible para observar desigualdades de desempeño en tecnologías de voz y orientar decisiones de investigación, evaluación y mejora.

La equidad no se presume por el carácter multilingüe de un modelo: debe examinarse con resultados desagregados, criterios adecuados a cada idioma y participación de personas con conocimiento lingüístico y cultural de las comunidades evaluadas.

El benchmark puede ayudar a detectar brechas y priorizar nuevas evaluaciones; por sí solo no resuelve la falta de datos, representación o recursos para cada lengua.

El pipeline implementado contempla:

- Estandarización del audio a 16 kHz, canal mono y formato `float32`.
- Normalización Unicode y reglas de procesamiento textual.
- Selección reproducible de muestras mediante semilla fija.

- Evaluación con métricas WER y CER.
- Uso de caché persistente para reutilizar datos procesados.

En la preparación de datos se documentó que la caché persistente redujo el tiempo de preparación de 106 minutos a menos de un minuto en ejecuciones posteriores. Esta mejora corresponde a la preparación del experimento y no debe interpretarse como ahorro mensual de operación productiva.

Beneficios cuantificables

Para dimensionar el posible beneficio operativo se modela un escenario ilustrativo de 10,000 clips mensuales.

Bajo los supuestos del Anexo A, un minuto de trabajo manual por clip, 1.491 segundos de inferencia por clip y revisión humana del 15 % de los resultados a un minuto por clip revisado, el tiempo de trabajo estimado baja de 166.67 a 29.14 horas mensuales.

El ahorro potencial es de:

137.53 horas mensuales (82.5 %)

Es una proyección para dimensionar un piloto, no un ahorro observado ni un compromiso de capacidad. Deberá recalibrarse con tiempos reales, volumen y tasa de revisión del sponsor.

Beneficios intangibles

La solución fortalece la toma de decisiones al ofrecer métricas desagregadas por idioma en lugar de depender exclusivamente de promedios globales.

Mejora la calidad del proceso al incorporar normalización y criterios de evaluación adecuados a cada sistema de escritura.

Simplifica el trabajo de investigación mediante pipelines, caché y resultados reproducibles.

Finalmente, aporta una base para convertir la equidad lingüística en un criterio técnico verificable: no basta con que un sistema admita varios idiomas, es necesario comprobar cómo funciona en cada uno y transparentar dónde falla.

4. Inversión, operación y condiciones de implementación

Se recomienda avanzar por etapas. Primero, cerrar la validación técnica del benchmark, después, ejecutar un piloto acotado con volúmenes, idiomas y criterios de aceptación acordados; y solo entonces decidir una integración productiva.

El prototipo se ejecutó en Google Colab con GPU Tesla T4 (14.56 GB de VRAM reportados). El notebook recomienda una GPU de al menos 16 GB, por lo que la infraestructura observada no debe asumirse como dimensionamiento definitivo para producción.

Como estimación preliminar de planeación (no cotización de proveedor) se considera:

- 120 horas de desarrollo a MXN $600 por hora: MXN $72,000.
- 40 horas de implementación a MXN $600 por hora: MXN $24,000.
- 30 horas-GPU mensuales a MXN $45 por hora: MXN $1,350.
- Almacenamiento, monitoreo y respaldos: MXN $650 mensuales.

El costo operativo estimado es de MXN $2,000 mensuales. El costo total de propiedad estimado para 12 meses es de MXN $120,000.

Concepto	**Importe MXN**
Desarrollo	$72,000
Implementación	$24,000
Operación mensual	$2,000
TCO estimado a 12 meses	$120,000

Esta estimación no incluye impuestos, servicios de API, integración empresarial, soporte extendido, anotación adicional ni revisión humana. Los supuestos deben sustituirse por cotizaciones y tarifas reales antes de autorizar presupuesto.

5. Riesgos principales y mitigación

Riesgo	**Medida de mitigación propuesta**
Cobertura lingüística limitada	El experimento final reporta ocho idiomas. Ampliar progresivamente el conjunto y validar con hablantes o revisores competentes antes de extrapolar resultados a otras lenguas o dialectos.
Errores de inferencia y reproducibilidad	Los registros del notebook muestran fallos en dos audios (alemán e italiano) asociados a entradas que activan el modo de audio largo. Corregir el manejo de duración, reejecutar la prueba completa y conservar logs, versiones y hashes de datos.
Sesgo de medición	Mantener normalización específica por idioma; usar CER para escrituras sin espacios y WER solo donde la segmentación léxica sea válida. Reportar métricas por idioma, no únicamente promedios.
Capacidad e infraestructura	Dimensionar GPU y concurrencia mediante pruebas de carga.
Costos, privacidad y licencias	Establecer presupuesto por volumen, monitorear consumo, limitar datos a fuentes autorizadas y revisar licencias y condiciones de uso antes de incorporar datos o servicios externos.

6. Transferencia y continuidad

Al sponsor se propone transferir:

1. Repositorio de código y notebooks reproducibles.
2. Pipeline de ingesta, normalización y evaluación.

3. Resultados WER/CER y desglose por idioma.
4. Documentación de configuración, dependencias, limitaciones y criterios de selección.
5. Archivos de resultados y visualizaciones.
6. Guía de ejecución y mantenimiento.

El repositorio reportado por el equipo es VoiceBenchmark. El código se identifica con licencia MIT y el corpus FLEURS con CC-BY-4.0, sujeto a conservar las atribuciones y verificar las condiciones aplicables.

La recomendación ejecutiva es autorizar un piloto técnico condicionado con enfoque de equidad lingüística, no un despliegue general inmediato.

Sus condiciones de salida deben ser:

- Ejecución completa sin muestras fallidas.
- Resultados estables en una prueba ampliada.
- Validación lingüística por idioma.
- Medición de costos reales.
- Aprobación de privacidad y licenciamiento.

Con estas condiciones, CLEAR podrá utilizar el benchmark como mecanismo de observación y seguimiento de brechas en sistemas ASR, aportando evidencia para que la innovación en voz avance hacia una participación más equitativa de las comunidades lingüísticas.

Anexo A. Supuestos y cálculo de beneficios y costos

A.1 Beneficio mensual de ahorro de tiempo

El siguiente cálculo es un escenario para dimensionar el piloto.

Supuestos:

- Volumen mensual: 10,000 clips.
- Trabajo manual de referencia: 1 minuto por clip.
- Inferencia automatizada: 1.491 segundos por clip.
- Control humano: revisión del 15 % de los clips, a 1 minuto por clip revisado.

Cálculo:

$$
\begin{aligned}
T_{\text{manual}} &= \frac{10{,}000 \times 1 \text{ min}}{60} = 166{,}67 \text{ h/mes} \\
T_{\text{inferencia}} &= \frac{10{,}000 \times 1{,}491 \text{ s}}{3{,}600} = 4{,}14 \text{ h/mes} \\
T_{\text{revision}} &= \frac{10{,}000 \times 0{,}15 \times 1 \text{ min}}{60} = 25{,}00 \text{ h/mes} \\
T_{\text{automatizado}} &= 4{,}14 + 25{,}00 = 29{,}14 \text{ h/mes} \\
\mathit{Ahorro} &= 166{,}67 - 29{,}14 = 137{,}53 \text{ h/mes} \\
\mathit{Reduccion} &= \frac{137{,}53}{166{,}67} \times 100 = 82{,}5\,\%
\end{aligned}
$$

El ahorro de tiempo no equivale automáticamente a ahorro de caja: representa capacidad laboral potencial liberada. Para monetizarlo se requiere conocer el costo laboral real, la proporción de tiempo efectivamente reasignable y si se evita gasto incremental.

No se reporta reducción de errores mensual ni incremento de ventas porque los avances no contienen una línea base operativa mensual que permita calcularlos de forma defendible.

A.2 Estimación de inversión y costo total de propiedad

Concepto	**Base supuesta**	**Importe MXN**
Desarrollo	120 h × \$600/h	\$72,000
Implementación	40 h × \$600/h	\$24,000
GPU mensual	30 h × \$45/h	\$1,350
Almacenamiento, monitoreo y respaldos	Cuota mensual supuesta	\$650
Operación mensual	GPU + servicios básicos	\$2,000
Operación 12 meses	12 × \$2,000	\$24,000
TCO estimado a 12 meses	\$72,000 + \$24,000 + \$24,000	**\$120,000**

Las tarifas son supuestos de planeación, no precios observados ni cotizaciones. No incluyen impuestos, servicios de API, integración empresarial, soporte de terceros, anotación de nuevos corpus, seguridad especializada ni costo de revisores humanos.

El costo de GPU debe recalcularse con el proveedor, tipo de acelerador, concurrencia, almacenamiento y volumen real.

A.3 Condiciones de aceptación recomendadas para el piloto

1. Reejecutar la evaluación completa sin errores de procesamiento y confirmar el denominador efectivo de las métricas.
2. Congelar versiones de modelo, librerías, datos y reglas de normalización.
3. Publicar WER y CER por idioma, además de promedios macro y micro claramente identificados; incluir dispersión y tamaño de muestra.
4. Validar muestras con hablantes competentes y, cuando sea posible, representantes de las comunidades.
5. Medir latencia, VRAM, costo por mil audios y tasa de revisión en la infraestructura objetivo.

Anexo B. Declaración de uso de IA y referencias

Los avances técnicos del proyecto documentan el uso de herramientas de IA como apoyo para estructuración, depuración de código, evaluación, métricas y redacción.

El equipo conserva la responsabilidad de revisar, ejecutar y validar los resultados, el código y las conclusiones antes de su difusión. Esta declaración deberá cotejarse con el registro final de herramientas y contribuciones del equipo antes de la publicación institucional.

Referencias bibliográficas

1. CLEAR – Coalition for Language Equity in AI Research. (2026). *The Tokenizer Tax*. Portal oficial de CLEAR. Estudio sobre disparidades de tokenización entre idiomas. Disponible en: `https://clear-languages.org/blog/the-tokenizer-tax`

2. Conneau, A., Ma, M., Khanuja, S., Zhang, Y., Axelrod, V., Dalmia, S., Riesa, J., Rivera, C., y Bapna, A. (2022). *FLEURS: Few-shot Learning Evaluation of Universal Representations of Speech*. arXiv:2205.12446. `https://arxiv.org/abs/2205.12446`

3. Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., y Sutskever, I. (2023). *Robust Speech Recognition via Large-Scale Weak Supervision*. Proceedings of the 40th International Conference on Machine Learning, 202, 28492–28518. `https://proceedings.mlr.press/v202/radford23a.html`

4. Thennal, D. K., James, J., Gopinath, D. P., y Ashraf, K. (2025). *Advocating Character Error Rate for Multilingual ASR Evaluation*. Findings of the Association for Computational Linguistics: NAACL 2025, 4941–4950. `https://doi.org/10.18653/v1/2025.findings-naacl.277`

5. Karita, S., Sproat, R., y Ishikawa, H. (2023). *Lenient Evaluation of Japanese Speech Recognition: Modeling Naturally Occurring Spelling Inconsistency*. Proceedings of the Workshop on Computation and Written Language (CAWL 2023), 61–70. `https://doi.org/10.18653/v1/2023.cawl-1.8`

6. Ahia, O., Kumar, S., Gonen, H., Kasai, J., Mortensen, D. R., Smith, N. A., y Tsvetkov, Y. (2023). *Do All Languages Cost the Same? Tokenization in the Era of Commercial Language Models*. Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, 9904–9923. `https://doi.org/10.18653/v1/2023.emnlp-main.614`